

PageRank sobre la blogosfera política de EE.UU.

(elección presidencial de 2004 en estados unidos)

Francisco Reyes Alonso Aqueveque
Alex Nieves

Repositorio: <https://github.com/Prodigy0101/Proyecto-2-Algebra-Lineal-Avanzada-y-Modelamiento>

1. Cómo reproducir el trabajo

Todo el desarrollo (código, respuestas P1–P8 y figuras) está en un único notebook, `proyecto_pagerank.ipynb`, organizado en el mismo orden del enunciado. Para ejecutarlo se necesitan las siguientes librerías descargadas, las cuales se pueden instalar con el siguiente comando:

```
pip install numpy scipy networkx matplotlib pandas jupyter
jupyter notebook proyecto_pagerank.ipynb    # o subirlo a Google Colab
Kernel -> Restart & Run All
```

La primera celda descarga sola el dataset; no hay pasos manuales y los resultados son reproducibles. Los datos corresponden a la red *moreno_blogs* de KONECT; usamos el archivo GML original de Adamic & Glance porque, además de los enlaces, incluye la URL y la orientación política de cada blog, atributos que necesitamos para la interpretación y que la versión de KONECT no distribuye.

2. La red elegida y por qué

Los nodos son blogs políticos de EE.UU. activos en la campaña Bush–Kerry, etiquetados como liberales o conservadores; una arista $j \rightarrow i$ indica que la portada del blog j enlaza al blog i (principalmente *blogrolls*, las listas de blogs recomendados). La red fue capturada a comienzos de 2005 para estudiar la polarización de la blogosfera.

La elegimos por tres razones. Primero, sus nodos tienen nombres reconocibles como Daily Kos, Instapundit, Drudge Report, lo que permite validar el ranking con conocimiento del dominio en lugar de aceptarlo a ciegas. Segundo, la etiqueta política es un atributo natural que habilita una pregunta más rica que “¿quién es el más importante?”: permite comparar la influencia *entre comunidades*. Tercero, los blogrolls son enlaces de recomendación, es decir, exactamente el tipo de “voto” para el que PageRank fue diseñado. Siguiendo a KONECT, trabajamos con el grafo simple, sin nodos aislados ni enlaces duplicados.

Estadística	Valor
Nodos n	1 224 (588 liberales, 636 conservadores)
Aristas m	19 022
Grado medio de entrada / salida	15.5
Nodo de mayor grado de entrada	dailykos.com (337 enlaces)
Densidad	$\approx 1.3 \%$
Nodos colgantes (sin salida)	160 (13 %)

Tabla 1: Estadísticas básicas de la red.

3. Pregunta e hipótesis

Pregunta: ¿Qué blogs fueron los más influyentes de la blogosfera política de 2004 según PageRank y la influencia agregada está balanceada entre las comunidades liberal y conservadora, o una de ellas concentra los nodos más centrales?

Hipótesis: Dado que tenemos varias hipótesis estas estarán enumeradas (1) los blogs más enlazados —dailykos.com e instapundit.com— encabezarán el ranking, porque en esta red los blogrolls funcionan como votos directos; (2) el top-20 tendría leve mayoría conservadora, pues esa comunidad tiene mas nodos o paginas ; (3) habría discrepancias puntuales: blogs recomendados por sitios muy influyentes escalarían posiciones respecto de su número de enlaces, y blogs enlazados solo desde la periferia caerían.

4. Qué hicimos (metodología en breve)

La exploración previa mostró que ambas distribuciones de grado tienen cola pesada (la mayoría de los blogs recibe un puñado de enlaces y unos pocos concentran cientos). La mayor componente fuerte cubre cerca de dos tercios de los nodos. También detectamos que un 13 % de los blogs no enlaza a nadie: en la marcha aleatoria el caminante quedaría atrapado en ellos y la probabilidad se fugaría del sistema. Ambos problemas se resuelven con las dos correcciones estándar del modelo: los nodos colgantes pasan a saltar uniformemente a cualquier blog (matriz S), y se agrega la teleportación con factor $\alpha = 0,85$, que vuelve la Matriz de Google positiva y garantiza una única distribución estacionaria sin importar la estructura del grafo. Elegimos ese α porque equilibra dos cosas: valores mayores respetan más la estructura real de enlaces pero hacen la convergencia lenta e inestable; valores menores convergen rápido pero empujan el ranking hacia el uniforme. Por temas de eficiencia nunca construimos la matriz densa.

La iteración de potencias, partiendo del vector uniforme y ocupando una tolerancia 10^{-10} , convergió en **107 iteraciones**. La curva de error (Figura 1) es una recta en escala logarítmica con razón empírica $\approx \alpha$, exactamente el decaimiento geométrico que la teoría predice. El vector final se comporta como un modelo matemático.




Figura 1: Error entre iterados sucesivos y el límite (escala logarítmica), junto a la referencia geométrica $C \alpha^k$.

5. Resultados: los blogs más influyentes

El top-20 (Tabla 2) es un “quién es quién” verificable de la blogosfera de 2004, dailykos.com era el mayor blog demócrata y un actor central de la movilización online de la campaña de 2004; arios y Talking Points Memo eran los referentes progresistas más citados; hay otros blo individuales conservadores y liberales que también destacaron en el top. Que un algoritmo que solo mira la estructura de enlaces recupere esta lista es el principal argumento a favor de PageRank en esta red.

Rango	Blog	PageRank	d_{in}	d_{out}	Orient.
1	dailykos.com	0.0189	337	46	L
2	atrios.blogspot.com	0.0160	263	87	L
3	instapundit.com	0.0133	276	86	C
4	blogsforbush.com	0.0131	211	256	C
5	talkingpointsmemo.com	0.0131	268	14	L
6	michellemalkin.com	0.0115	200	28	C
7	drudgereport.com	0.0113	238	5	C
8	washingtonmonthly.com	0.0111	201	55	L
9	powerlineblog.com	0.0094	220	15	C
10	andrewsullivan.com	0.0091	143	0	C
11	juancole.com	0.0090	165	9	L
12	littlegreenfootballs.com/weblog	0.0089	181	27	C
13	vodkapundit.com	0.0075	105	66	C
14	rightwingnews.com	0.0074	119	3	C
15	volokh.com	0.0072	107	24	C
16	nationalreview.com/thecorner	0.0071	135	7	C
17	hughhewitt.com	0.0070	157	68	C
18	truthlaidbear.com	0.0068	187	17	C
19	prospect.org/weblog	0.0066	112	32	L
20	freerepublic.com	0.0063	81	0	C

Tabla 2: Los 20 nodos de mayor PageRank (L = liberal, C = conservador).

6. PageRank no es contar enlaces

La correlación entre PageRank y enlaces recibidos es alta. En una red donde los enlaces son recomendaciones explícitas, ser muy recomendado casi siempre implica ser influyente. Lo interesante está en las excepciones. **freerepublic.com** recibe solo 81 enlaces (puesto #50 por ese conteo) y sin embargo queda #20 en PageRank: lo recomiendan los blogs conservadores más influyentes de la red (michellemalkin.com, powerlineblog.com...), y cada una de esas recomendaciones vale mucho. Lo mismo le pasa a vodkapundit.com (#31 $\rightarrow$ #13). El caso opuesto es **redstate.org**: es #80 por conteo de enlaces, pero cae al #164 en PageRank porque sus enlaces vienen de blogs periféricos, cada uno con poca importancia que transferir y repartida entre muchos destinos. En esta asimetría importa más *quién* te recomienda que *cuántos* es justamente la “relevancia recursiva” que distingue a PageRank de la centralidad de grado.




Figura 2: PageRank vs. enlaces recibidos; top-10 destacados (azul = liberal, rojo = conservador).

7. ¿Qué comunidad concentra la influencia?

El subgrafo de los 40 blogs más influyentes (Figura 3) se separa a simple vista en dos bloques; liberal y conservador, y la cuantificación lo confirma: más del 80 % de las aristas de esa élite conecta blogs de la misma orientación. Es la polarización famosa de “divided they blog” es reproducida con solo los nodos top; los puentes entre mundos son escasos.

Sobre el balance: el top-20 tiene mayoría conservadora (14 de 20), pero los dos primeros lugares son liberales y la masa total de PageRank queda casi empatada entre ambas comunidades, en una proporción prácticamente idéntica a la composición de la red. La lectura fina es que ninguna comunidad “domina” la influencia total, pero la distribuyen de forma opuesta: los liberales la concentran en unos pocos gigantes (dailykos, arios, TPM) mientras los conservadores reparten la suya entre una élite más ancha, coherente con su cultura de enlazado más densa y con la existencia de directorios como blogsforbush.com.




Figura 3: Subgrafo de los 40 nodos de mayor PageRank (tamaño $\propto$ PageRank, color = orientación política).

8. Discusión y conclusiones

La hipótesis se cumplió en lo esencial: dailykos.com fue top-1, la correlación con el conteo de enlaces fue alta, el top-20 resultó de mayoría conservadora y aparecieron las discrepancias previstas, todas interpretables. hubieron dos cosas no las anticipamos: que arios superara a instapundit en el segundo lugar, y el patrón de concentración opuesto entre comunidades (su comportamiento), que terminó siendo el hallazgo más interesante del análisis. La pregunta quedó respondida en gran medida y con un agregado al propósito de PageRank en este caso; mide influencia estructural dentro de la red de recomendaciones, un buen proxy validado aquí por el conocimiento histórico pero no una medición directa de audiencia o impacto.

Limitaciones: El modelo idealiza la idea de que la gente salta uniformemente de blog a blog. El modelo ignora los enlaces dentro de los posts y su frecuencia, lo que se mide es reputación estructural, no tráfico. Los nodos colgantes son muy frecuentes y, aunque la corrección estándar controla el problema, blogs colgantes populares como freerepublic.com o andrewsullivan.com absorben importancia sin devolverla por enlaces reales, por lo que su posición puede quedar levemente inflada. La densidad de la red está en un rango donde PageRank es informativo, pero al no ser fuertemente conexas el resultado depende de la teleportación.

Preguntas nuevas: ¿La élite conservadora más ancha se explica por estrategia de enlazado (directorios) o por estructura comunitaria? ¿Qué tan sensible es el balance entre grupos al valor de α ? ¿Qué blogs puentean mejor ambas comunidades?

En simple: imaginamos un lector incansable que navega por los blogs recomendados de página en página (y a veces salta a uno cualquiera); el PageRank de un blog es cuánto tiempo pasa ahí ese lector eterno. Con esa regla tan simple redescubrimos a los blogs que marcaron la elección de 2004, vimos una blogosfera partida en dos mundos que casi no se recomendaban entre sí, y confirmamos que para ser influyente no basta con que muchos te recomienden, importa que te recomienden los influyentes.

Referencias

- [1] Adamic, L. & Glance, N. (2005). *The political blogosphere and the 2004 U.S. election: divided they blog*. Proc. 3rd Intl. Workshop on Link Discovery.
- [2] KONECT — The Koblenz Network Collection, red *moreno_blogs*. http://konect.cc/networks/moreno_blogs/
- [3] Brin, S. & Page, L. (1998). *The anatomy of a large-scale hypertextual Web search engine*. Computer Networks and ISDN Systems.